



Say anything, It's STiTy.

무엇이든 말해주세요. 저는 스티티입니다.

시스템경영공학과 김규연 | 인공지능융합전공 정다현
글로벌경영학과 전유진 | 인공지능융합전공 정진웅
영상학과 최윤서


2025-2 Co-Deep Learning Program

우리 팀은 서로 언어가 다르더라도 실시간으로 대화할 수 있도록 하는 **동시 통역 프로그램 개발**을 목표로 합니다.
이를 위해, 자연스러운 대화의 흐름을 방해하지 않는 **0.5초 미만 초저지연 응답 구현**을 위한 연구를 진행하였습니다.

01

기존 STT* 서비스

번역만 제공하는 서비스는 원활한 의사소통이 불가능하며,
상용 STT 서비스는 **3~5초** 수준의 지연을 가집니다.
대화의 간격이 약 **0.2초**로 형성된다는 점을 생각하면,
이는 적절하지 않습니다.



*STT: speech-to-text의 약자로, 사람의 음성을 컴퓨터가 인식하여 텍스트(문자)로 변환하는 기술

02


기저 모델(Whisper) 개조

1) Original Whisper




최대 30초의 고정된 오디오 입력을 받아 오디오 입력이 종료되면 한 번에 출력을 내놓는 구조
실시간성이 존재하지 않음 (입력을 세분화하거나, 입력 중간에 출력을 멈추고 결과를 보내야 함)

2) Chunked Upload (입력 세분화)



500ms 단위로 오디오를 전송하여 여러 번의 출력을 내놓는 구조
단순한 실시간 입출력으로 개조, VAD 감지 결과로 출력을 종료하므로 발화 종료 시에만 출력

3) Simul-Streaming (출력 조기 종료)



매 출력 반복마다 일정 임계점 이내에 Attention Peak (모델이 판단한 오디오와 의미가 일치하는 지점)가 존재하면 출력을 조기 종료함. 여러 조기 종료 기준을 적용하여 출력.

03

의미 분절 매커니즘 도입


모델의 실시간성을 더욱 개선하고자, 문장이 완전히 끝나기 전이라도 의미가 자립하는 지점마다 정보를 확정(커밋)하는 매커니즘 제안.

→ 출력 고정성 확보 및 지연 감소

- 1순위 : 종결부호(., ?, !) 기반 경계
- 2순위 : 음향 신호 기반 경계(VAD 공백 + CIF 신호)
- 3순위 : 접속/전환어(키워드) 기반 경계

04

모델 성능 평가



05

적용



성균관대학교 영어 시사토론 중앙동아리
Time 정기 세션 적용 (25.11.06)



IBM Qiskit Fall Fest 2025
with SKKU 행사 적용 (2025.11.21)

06

의의 및 향후 목표

- STT 시스템에서 '저지연 · 고정 출력' 조건의 가능성을 입증함.
 - 저지연과 최소 품질 유지를 동시에 만족하는 구조로 개선할 계획임.
- 화자 분리 및 다화자 처리 연구를 추가해 실시간 대화 시스템 완성